

Programación para Data Science

Unidad 5: Adquisición de datos en Python - Ejercicios y preguntas

Ejercicio 1

Seleccionad y descargad cualquier fichero de datos de alguno de los portales comentados en el notebook de esta unidad.

Cargad los datos en una variable Python (podéis usar [pandas](http://pandas.pydata.org/) (<http://pandas.pydata.org/>) si queréis). Mostrad el número de muestras que contiene el conjunto de datos y los atributos disponibles para cada muestra.

```
In [1]: # Respuesta
```

Pregunta 1

Queremos saber cuántas personas hay en el espacio en un momento dado. Identificad qué método de la siguiente API (<http://open-notify.org/Open-Notify-API>) podemos utilizar para obtener este dato y contestad a las siguientes preguntas:

1. ¿A qué URL realizaremos la petición?
2. ¿Qué tipo de petición HTTP (qué acción) tendremos que realizar a la API para obtener los datos deseados?
3. ¿En qué formato obtendremos la respuesta de la API seleccionada?
4. ¿En qué campo de la respuesta encontraremos la información que buscamos?

Respuesta

Ejercicio 2

Implementad una función que devuelva el número de personas que hay actualmente en el espacio.

```
In [2]: # Respuesta
```

Ejercicio 3

Programad una función que muestre la fecha y hora de los 10 próximos pases de la estación espacial internacional (ISS) por encima de una localización concreta (especificada por su dirección postal).

Pista: Pensad que podéis combinar resultados de varias APIs!

In [4]: # Respuesta

Pregunta 2

¿Qué es la *scrapy shell*? Describid para qué sirve y poned algún ejemplo de su uso.

Respuesta

Ejercicio 4

KDnuggets (<http://www.kdnuggets.com/>) es una web con contenido sobre data science. Entre otros, la web mantiene un listado de ofertas de trabajo relacionadas con el ámbito.

Programad un crawler que extraiga los títulos de todas las ofertas de trabajo de KDnuggets.

Para hacerlo, utilizad la estructura de crawler que hemos visto en el notebook de esta unidad, **modificando únicamente dos líneas de código**:

- La URL de inicio.
- La expresión XPath que selecciona el contenido a capturar.

Nota: Si la ejecución del crawler os devuelve un error `ReactorNotRestartable`, reiniciad el kernel del notebook (en el menú, Kernel - Restart).

```

In [1]: # Importamos scrapy
import scrapy
from scrapy.crawler import CrawlerProcess

# Creamos la araña
class uoc_spider(scrapy.Spider):

    # Asignamos un nombre a la araña
    name = "uoc_spider"

    # Indicamos la url que queremos analizar en primer lugar
    # Includ aquí la URL de inicio:
    #####
    start_urls = [
        ""
    ]
    #####

    # Definimos el analizador
    def parse(self, response):
        # Extraemos el título del grado
        # Includ aquí la expresión xpath que nos devuelve los títulos de las ofertas de trabajo
        #####
        for t in response.xpath('//'):
            #####
            yield {
                'title': t.extract()
            }

if __name__ == "__main__":

    # Creamos un crawler
    process = CrawlerProcess({
        'USER_AGENT': 'Mozilla/4.0 (compatible; MSIE 7.0; Windows NT 5.1)',
        'DOWNLOAD_HANDLERS': {'s3': None},
        'LOG_ENABLED': False
    })

    # Inicializamos el crawler con nuestra araña
    process.crawl(uoc_spider)

    # Lanzamos la araña
    process.start()

```



```
INFO:scrapy.utils.log:Scrapy 1.0.3 started (bot: scrapybot)
INFO:scrapy.utils.log:Optional features available: ssl, http11, boto
INFO:scrapy.utils.log:Overridden settings: {'USER_AGENT': 'Mozilla/4.0 (compatible; MSIE 7.0; Windows NT 5.1)', 'LOG_ENABLED': False}
INFO:scrapy.middleware:Enabled extensions: CloseSpider, TelnetConsole, LogStats, CoreStats, SpiderState
INFO:scrapy.middleware:Enabled downloader middlewares: HttpAuthMiddleware, DownloadTimeoutMiddleware, UserAgentMiddleware, RetryMiddleware, DefaultHeadersMiddleware, MetaRefreshMiddleware, HttpCompressionMiddleware, RedirectMiddleware, CookiesMiddleware, ChunkedTransferMiddleware, DownloaderStats
INFO:scrapy.middleware:Enabled spider middlewares: HttpErrorMiddleware, OffsiteMiddleware, RefererMiddleware, UrlLengthMiddleware, DepthMiddleware
INFO:scrapy.middleware:Enabled item pipelines:
INFO:scrapy.core.engine:Spider opened
INFO:scrapy.extensions.logstats:Crawled 0 pages (at 0 pages/min), scraped 0 items (at 0 items/min)
DEBUG:scrapy.telnet:Telnet console listening on 127.0.0.1:6024
DEBUG:scrapy.core.engine:Crawled (200) <GET http://www.kdnuggets.com/jobs/index.html> (referer: None)
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Chubb: Customer Experience & Marketing Analytics Manager'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Live.xyz: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Turner: Sr. Operations Research Analyst / Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Turner: Advisor Analytics Architect'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Apple: Software Engineer \u2013 Local Search'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'PeachIH: Data Scientist, Machine Learning Engineer'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Eindhoven University of Technology: Full Professor Database Technology'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Corios: IT Systems Administrator'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Aetna: Lead Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Accenture: Artificial Intelligence Experienced Researcher'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'LeapYear: Lead Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com
```

```
m/jobs/index.html>
{'title': u'IRIS Advanced Engineering: TecnioSpring Data Mining Fellowshipship'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Schwab: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Stylight: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Freeletics: Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Apple: Data Mining Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Metis: Evangelist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Altria: Applied Statistician, Regulatory Affairs'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Netflix: Manager, Content Programming Science & Algorithms'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Aetna: Principal Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'ACI Worldwide: Sr. Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'R2: DevOps for Data Science'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'NEC Labs: Researcher'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'89degrees: SAS Campaign Developer'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'89degrees: SAS Administrator'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'89degrees: Enterprise Data Architect'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Scripps: Director, Data Science'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Scripps: Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Dstillery: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.com/jobs/index.html>
{'title': u'Senior Data Scientist (Inv / Risk / Marketing) NY & BOS | Recent PhD'}
```

```
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'FeatureX: Software Engineer'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'FeatureX: Machine Learning Research Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'FeatureX: Computer Vision Research Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Aetna: Lead Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'U. of Calgary: Professor, Tier 1 Canada Research Chair,
Biomedical Engineering'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Aetna: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Aetna: Principal Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Stylight: Senior Data Scientist'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Ferris State University: Assistant Professor Business Da
ta Analytics'}
DEBUG:scrapy.core.scrapers:Scraped from <200 http://www.kdnuggets.co
m/jobs/index.html>
{'title': u'Accenture: Data Scientist'}
INFO:scrapy.core.engine:Closing spider (finished)
INFO:scrapy.statscollectors:Dumping Scrapy stats:
{'downloader/request_bytes': 247,
 'downloader/request_count': 1,
 'downloader/request_method_count/GET': 1,
 'downloader/response_bytes': 10204,
 'downloader/response_count': 1,
 'downloader/response_status_count/200': 1,
 'finish_reason': 'finished',
 'finish_time': datetime.datetime(2017, 3, 29, 9, 24, 51, 977869),
 'item_scraped_count': 40,
 'log_count/DEBUG': 42,
 'log_count/INFO': 7,
 'response_received_count': 1,
 'scheduler/dequeued': 1,
 'scheduler/dequeued/memory': 1,
 'scheduler/enqueued': 1,
 'scheduler/enqueued/memory': 1,
 'start_time': datetime.datetime(2017, 3, 29, 9, 24, 51, 448811)}
INFO:scrapy.core.engine:Spider closed (finished)
```


Pregunta 3

¿Qué es OAuth? Explicad una situación dónde sería útil usar OAuth en vez de un protocolo de autenticación tradicional basado en usuario y contraseña.

Respuesta